

M01 — Architecture & Product Blueprint

AI UGC Advertising SaaS · Phase 1 : conception, aucun code applicatif

JALON	STATUT	DATE	DESTINATAIRE
M01 · Blueprint	Terminé — à valider	5 septembre 2026	Senior Developer
DÉPÔT	BRANCHE	COMMIT	VOLUME
abdoulasani/Afrinext	claude/new-session-igslex	12b61a6	7 fichiers · 3 083 lignes

1. Objet du jalon

Le jalon M01 couvre la **Phase 1 du master prompt** : produire une architecture et un blueprint produit complets pour un SaaS de publicité UGC générée par IA, à partir de trois sources fournies. La consigne explicite était de **ne pas écrire de code** avant que l'architecture ne soit posée et validée. Cette consigne a été respectée : le dépôt ne contient à ce stade que de la documentation.

Ce rapport n'est pas un résumé du blueprint. Il est conçu comme un **document de revue** : il liste les décisions structurantes prises, celles qui engagent la suite du projet, les hypothèses chiffrées à vérifier, et les points sur lesquels une validation ou une correction est explicitement demandée avant de démarrer la Phase 01 du build order.

2. Sources analysées

SOURCE	TRAITEMENT EFFECTUÉ	CE QUI EN A ÉTÉ RETENU
Vidéo tutorielle How To Create Ultra Real AI Avatar 15 min 28 s	Décomposition image par image (échantillonnage 1 image / 12 s, 77 images analysées). La piste audio n'a pas pu être transcrite (téléchargement du modèle ASR bloqué par le proxy sortant) — l'analyse repose donc sur les visuels et les sous-titres incrustés, qui couvrent l'intégralité du workflow.	Le workflow réel en 6 étapes, les outils employés, la structure des prompts, le point de décision humaine unique, et les limites du procédé.
avatar-6c-prompt-engine 1 fichier	Lecture intégrale.	La méthode 6C (Character, Camera, Clothing, Context, Cinematic light, Consistency) et le vocabulaire « iPhone realism ».
ugc-ad-engine 8 fichiers, ~1 290 lignes	Lecture intégrale, références comprises.	Le pipeline angles → script → prompts vidéo, la bibliothèque de prompts caméra/voix, la table durée → nombre de mots, et surtout ads-method.md — la base de connaissance créative en 12 sections.

LE WORKFLOW RECONSTITUÉ DEPUIS LA VIDÉO

Pinterest (capture d'une créatrice réelle) → ChatGPT Work + skill 6C → Adobe Firefly (GPT Image 2, 9:16) → skill ugc-ad-engine sur une URL → 12 angles → *choix humain d'un angle* → script 6 clips / 38 s + feuille de prompts → Firefly Generate video (Gemini Omni Flash, 720p, 9:16) × 6 copier-coller → éditeur vidéo agentique → publicité finale de 25 s.

Durée : 45 à 60 minutes, dont une seule véritable décision humaine.

3. Livrables

FICHIER	LIGNES	CONTENU
docs/blueprint/README.md	61	Index, résumé en 10 points, conventions
docs/blueprint/00-analyse-sources.md	203	Analyse de la vidéo, critique des deux skills, risque juridique
docs/blueprint/01-produit.md	330	Sections A → E : executive summary, vision, utilisateurs, parcours, modules
docs/blueprint/02-moteur-ia.md	769	Sections F → K : architecture IA, orchestrateur, vidéo, personnages, éditeur, intelligence
docs/blueprint/03-plateforme.md	892	Sections L → Z : backend, front, schéma SQL, API, jobs, providers, sécurité, coûts, déploiement
docs/blueprint/04-diagrammes.md	439	Les 8 diagrammes ASCII demandés
docs/blueprint/05-roadmap-et-decision-finale.md	364	MVP/V1/V2, moat, stack finale, build order en 10 phases, risques
README.md	25	Point d'entrée du dépôt

Couverture des exigences du master prompt : les 26 sections A → Z sont traitées, les 4 volets MVP / V1 / V2 / Future Moat sont définis, les 8 diagrammes ASCII sont fournis, la stack finale (« THE RECOMMENDED ARCHITECTURE ») et le BUILD ORDER en 10 phases sont livrés avec, pour chaque phase, objectif, contenu, dépendances, risques et définition de « done ».

4. Décisions d'architecture engageantes

Les six décisions ci-dessous conditionnent tout le reste du projet. Elles sont celles dont la remise en cause ultérieure coûterait le plus cher.

D1 · Le pipeline est un DAG explicite, pas un agent LLM		BLOQUANT
RETENU	Graphe de nœuds persisté en PostgreSQL, exécuté par des workers BullMQ, avec états, dépendances, reprise partielle et compensation.	
ALTERNATIVES	Temporal · AWS Step Functions · chaînage naïf de jobs · agent LLM autonome.	
RAISON	Le pipeline est un graphe fixe à branches connues, pas un problème d'agent. Un agent qui « décide » d'appeler trois fois un modèle vidéo dépense 12 \$ sans prévenir. Le DAG en base est inspectable en SQL par le support et rend la reprise partielle triviale.	
RÉVERSIBILITÉ	Bonne — Temporal reste envisageable en V2 si le graphe dépasse ~20 nœuds.	

D2 · Toute sortie IA est un objet typé et validé, jamais du markdown re-parsé		BLOQUANT
RETENU	Contrats d'entrée et de sortie typés (Zod / JSON Schema) sur chaque nœud IA. Le markdown devient une vue dérivée.	
ALTERNATIVES	Conserver le format markdown des skills existants et parser le texte.	
RAISON	C'est la différence structurelle entre un skill conversationnel et un produit. Un parseur sur texte libre casse à la première variation de formatage du modèle.	
RÉVERSIBILITÉ	Faible — c'est une décision de fondation.	

D3 · Providers routés par « capabilities » déclarées en base de données

MAJEUR

RETENU	Chaque provider publie un descripteur (durées, audio natif, fidélité d'identité, coût/s, latence, politique de contenu, régions). Un routeur choisit par filtres + score. Chaque provider compile son propre prompt.
ALTERNATIVES	Provider unique · interface uniforme <code>generate(prompt, duration)</code> .
RAISON	Une interface uniforme nivelle par le bas et interdit d'exploiter le lip-sync natif ou la fidélité d'identité — précisément nos critères de qualité. Critère d'acceptation associé : ajouter un provider = 1 adaptateur (~200 lignes) + 1 ligne SQL, sans déploiement du cœur.
RÉVERSIBILITÉ	Moyenne.

D4 · Personnages propriétaires ou consentis — jamais de sosie non consenti

BLOQUANT

RETENU	Bibliothèque générée en interne (16 personnages au MVP) + clonage sur consentement horodaté et auditable. Détection de visage à l'ingestion, refus des correspondances de célébrités, provenance C2PA sur les sorties.
ALTERNATIVES	Reproduire l'étape 1 de la vidéo (capture d'une personne réelle sur Pinterest).
RAISON	Droit à l'image (art. 9 C. civ.), RGPD, <i>right of publicity</i> (AB 602, ELVIS Act), EU AI Act art. 50, politiques Meta/TikTok. Rétrofitter la conformité sur une base d'avatars illicites est impossible.
RÉVERSIBILITÉ	Nulle — décision de conception.

D5 · L'argent est estimé, réservé, attribué et plafonné avant d'être dépensé

BLOQUANT

RETENU	Grand livre de crédits en ajout seul, réservation atomique avant le premier appel payant, et quatre verrous indépendants : réservation, plafond par job, plafond par workspace et fenêtre glissante, kill switch par provider.
ALTERNATIVES	Metering Stripe natif · facturation a posteriori.
RAISON	La latence de synchronisation Stripe empêche de refuser une génération <i>avant</i> la dépense. Sans ces verrous, un bug de retry coûte des milliers d'euros avant détection.
RÉVERSIBILITÉ	Faible.

D6 · Un seul gate humain : le choix du concept créatif

MAJEUR

RETENU	Le job passe en <code>WAITING_INPUT</code> après la génération des concepts, avec un TTL de 7 jours. Tout le reste est asynchrone.
ALTERNATIVES	Validation du script en plus · automatisation totale sans gate.
RAISON	Le workflow analysé n'a qu'une seule décision humaine réelle : l'angle. On la conserve — c'est la décision qu'une machine ne devrait pas prendre — et on supprime les 45 minutes de travail mécanique.
RÉVERSIBILITÉ	Bonne.

5. Points nécessitant une validation explicite

Ce sont les sept points sur lesquels une réponse est attendue avant de démarrer la Phase 01. Une recommandation est formulée pour chacun ; le désaccord est prévu et documenté.

#	QUESTION POSÉE	RECOMMANDATION	CONSÉQUENCE SI LE CHOIX EST DIFFÉRENT
V1	Ordre de construction — construit-on la stratégie (Phase 03) avant la génération vidéo (Phase 05) ?	Oui. La stratégie est la seule couche non commoditisable ; la génération vidéo est louée par tout le monde. C'est aussi la partie démontrable sans dépenser un euro de génération.	Inverser donne une démo plus spectaculaire plus tôt, mais fabrique un générateur de plus et fait dépenser du COGS avant d'avoir validé la qualité créative.
V2	Monolithe modulaire + workers séparés, plutôt que des microservices ?	Oui , avec des frontières de modules strictes (règles de dépendance vérifiées en CI) pour permettre une extraction ultérieure.	Des microservices dès le départ coûtent, pour une équipe de 3 à 8 personnes, un temps d'ingénierie disproportionné avant le product-market fit.
V3	Cloudflare R2 plutôt que S3 pour le stockage objet ?	Oui. L'egress est nul chez R2 ; sur un produit vidéo servi plusieurs fois par publicité, S3 facturerait la sortie plus cher que le stockage.	S3 reste supérieur si l'on prévoit une intégration profonde à l'écosystème AWS — ce que l'architecture proposée n'utilise pas.
V4	Clerk pour l'authentification au MVP, malgré son coût par utilisateur actif ?	Oui , derrière une interface <code>AuthProvider</code> . Économiser 0,02 \$/MAU quand le COGS variable est de 10 à 30 \$ par publicité est une erreur de priorité.	Better Auth ou WorkOS sont les cibles de migration au-delà de ~20 000 MAU ou à l'arrivée d'exigences SSO entreprise.
V5	RLS PostgreSQL dès la Phase 01 , en plus du contrôle applicatif ?	Oui. Ceinture et bretelles assumées : la fuite inter-tenant est le seul incident qui tue un SaaS B2B, et rétrofitter la RLS est une migration douloureuse.	Sans RLS, un oubli de <code>WHERE workspace_id = ?</code> devient une fuite de données. Non recommandé.
V6	Périmètre du MVP — un seul format (9:16), 15 et 30 s, 16 personnages, 1 provider + 1 fallback ?	Oui. Le MVP doit prouver « URL → publicité diffusable en moins de 15 min » et rien d'autre.	Tout élargissement du périmètre repousse la mesure du facteur de régénération, dont dépend la grille tarifaire.
V7	Politique de personnages (D4) — acceptez-vous le surcoût de la bibliothèque propriétaire et du workflow de consentement ?	Oui. Quelques semaines d'ingénierie contre l'accès aux marchés entreprise, agence et UE.	Reproduire le procédé de la vidéo rend le produit invendable aux entreprises et expose à un risque juridique direct.

6. Hypothèses chiffrées à vérifier

ATTENTION — CHIFFRES NON VÉRIFIÉS

Les coûts ci-dessous sont des **ordres de grandeur établis à la date de rédaction**. Ils fondent la grille tarifaire proposée. Ils doivent être re-benchmarkés sur les providers réels **avant tout engagement de prix**. Ils sont signalés comme tels dans le blueprint.

HYPOTHÈSE	VALEUR RETENUE	COMMENT LA VÉRIFIER
Coût de génération vidéo	0,10 – 0,50 \$ / seconde selon le tier	Benchmark direct sur Veo, Omni Flash et Kling, tarifs API en vigueur
Facteur de régénération réel	1,6 – 2,2×	Mesure sur 50 publicités de test. C'est la variable la plus sensible du modèle économique
COGS d'une publicité de 30 s (tier standard)	10 – 14 \$	Découle des deux lignes précédentes

HYPOTHÈSE	VALEUR RETENUE	COMMENT LA VÉRIFIER
Coût IA texte par publicité	0,20 – 0,60 \$	Mesurable dès la Phase 03, sans génération vidéo
Marge brute cible	65 % au lancement → 75 % à maturité	Vérifiée en Phase 08 sur 100 publicités réelles
Taux d'extraction Brand DNA réussie	≥ 80 % des sites	Test sur 30 sites réels de verticales différentes (définition de done de la Phase 02)

SEUIL D'ALERTE

Si le facteur de régénération mesuré **dépasse 2,2**, la grille tarifaire proposée ne tient pas. La réponse correcte est alors de **retravailler le contrôle qualité, pas d'ajuster les prix** — d'où la dépendance explicite de la Phase 08 (facturation) à la Phase 05 (génération vidéo).

7. Points de désaccord avec les sources fournies

Le master prompt demandait de ne pas chercher à faire plaisir et de signaler ce qui est mauvais. Quatre points ont été relevés, tous argumentés dans le blueprint.

POINT	PROBLÈME IDENTIFIÉ	POSITION RETENUE
Sourcing des avatars <i>étape 1 de la vidéo</i>	Capturer l'image d'une créatrice réelle sur Pinterest pour générer son sosie n'est pas une zone grise juridique.	Supprimé du produit. Remplacé par bibliothèque propriétaire + clonage consenti (D4). \$00.3 du blueprint.
Biais esthétique codé en dur <i>skill 6C</i>	« European model-level beauty » figure dans les règles et dans l'exemple de référence.	Retiré. La sélection du personnage dérive de <code>BrandDNA.audience</code> . Argument commercial autant qu'éthique : le levier <i>liking</i> de Cialdini dit qu'on achète à des gens qui nous ressemblent.
« Ne jamais mentionner l'IA » <i>skill 6C</i>	Bonne règle de qualité de prompt, mais en collision frontale avec l'EU AI Act art. 50 et les politiques Meta/TikTok.	Conservée au niveau du prompt ; le disclosure devient une couche de sortie (C2PA + mention optionnelle), pas une décision du prompt.
Montage par agent conversationnel <i>étape 6 de la vidéo</i>	Séduisant en démo, intenable en production : non reproductible, non versionnable, non testable ; chaque modification relance un LLM.	Remplacé par un <code>EditPlan</code> déclaratif rendu par un moteur déterministe. L'utilisateur garde l'ergonomie conversationnelle — mais le LLM édite le plan, pas la vidéo.

8. Ce qui n'a pas été fait — et pourquoi

NON LIVRÉ	JUSTIFICATION
Tout code applicatif	Consigne explicite des sections 28 et 31 du master prompt : ne pas commencer à coder avant validation de l'architecture.
Transcription audio de la vidéo	Téléchargement du modèle ASR bloqué par le proxy sortant (403). Compensé par l'analyse image par image et les sous-titres incrustés, qui couvrent l'intégralité du workflow. Aucun impact identifié sur les conclusions , mais le point est signalé par honnêteté.

NON LIVRÉ	JUSTIFICATION
Prix fermes	Le master prompt demandait de ne pas fixer les prix arbitrairement. Une <i>méthode</i> de calcul et une grille indicative sont fournies ; les prix définitifs dépendent du benchmark de la section 6.
Choix définitif des providers	Le tableau fourni sera périmé sous six mois — c'est précisément l'argument de l'abstraction par capacités (D3). La liste est une position de départ, pas un engagement.
Maquettes d'interface	Hors périmètre de la Phase 1. Les parcours et les principes d'UI sont spécifiés (§B, §D, §M) ; le design visuel viendra avec la Phase 01.

9. Prochaine étape proposée

Phase 01 du build order — *Foundation*. Un squelette déployable, multi-tenant et sûr, sans aucune IA : monorepo pnpm/Turborepo, applications `api` / `web` / `worker` / `render`, PostgreSQL + Drizzle avec **RLS dès le premier jour**, Clerk, workspaces et memberships, R2 et uploads signés, Redis + BullMQ avec un job factice, OpenTelemetry + Sentry + PostHog, CI/CD et environnements de preview.

Définition de « done » proposée : deux workspaces coexistent ; un test d'isolation cross-tenant échoue correctement pour *chaque* table ; un job traverse la file de bout en bout ; une trace complète est visible dans l'outil d'observabilité.

Condition de démarrage : validation des points V1 à V7 de la section 5, ou formulation des corrections attendues.

10. Formulaire de revue

À compléter par le relecteur. Chaque ligne correspond à un point de la section 5.

RÉF.	VALIDÉ	À CORRIGER	COMMENTAIRE / CORRECTION DEMANDÉE
V1 Stratégie avant vidéo	☐	☐	
V2 Monolithe modulaire	☐	☐	
V3 Cloudflare R2	☐	☐	
V4 Clerk au MVP	☐	☐	
V5 RLS dès la Phase 01	☐	☐	
V6 Périmètre du MVP	☐	☐	
V7 Politique de personnages	☐	☐	
Décisions structurantes (section 4)			
D1 DAG explicite	☐	☐	
D2 Sorties IA typées	☐	☐	
D3 Routage par capacités	☐	☐	
D4 Personnages consentis	☐	☐	
D5 Contrôle des dépenses	☐	☐	
D6 Gate humain unique	☐	☐	

Verdict global

☐ Jalon validé — démarrage de la Phase 01 autorisé ☐ Validé sous réserve des corrections ci-dessus ☐ À reprendre

_____	_____	_____
Nom du relecteur	Date	Signature