

M05 — Provider Procurement & Experiment Setup

Préparation de E1 → E7 · 19 livrables · aucun SaaS construit

JALON	STATUT	DATE	DESTINATAIRE
M05 · setup	BLOCKED	6 septembre 2026	Senior Developer
LIVRABLES	PROVIDERS ÉVALUÉS	PAQUET	COÛT FACTURÉ
19 / 19 écrits	18 candidats	p0-setup/	0,00 \$

1. Verdict

DÉCISION

M05 STATUS : BLOCKED · P0 EXECUTION : BLOCKED

19 livrables sur 19 sont écrits. Ce qui manque n'est pas la préparation, c'est l'accès. Et M05 a produit un diagnostic bien plus précis que « pas de clés » :

Le proxy sortant de cet environnement refuse le CONNECT vers 11 hôtes fournisseurs sur 13. Une seule famille passe : Google Cloud.

EXPÉRIENCE	ÉTAT	CE QU'IL MANQUE EXACTEMENT
E1 · banque de plans	READY_ON_KEY	une clé Google — Veo est joignable
E2 · TTS français	READY_ON_KEY	la même clé Google
E4 · ASR français	READY_ON_KEY	la même clé Google
E5 · contrôle génératif	READY_ON_KEY	la même clé Google
E3 · lip-sync	BLOCKED	politique réseau — aucun credential ne le débloque
E6 · évaluation humaine	READY_ON_PEOPLE	3 à 5 francophones
E7 · régénération	dépendant	E1 et E3

2. Le fait qui structure tout M05

Le readiness check ne s'est pas contenté de constater l'absence de clés. Il a mesuré la connectivité réelle vers 14 endpoints, et interrogé l'état du proxy.

PREUVE · PROXY_STATUS_EVIDENCE.JSON

```
gateway answered 403 to CONNECT (policy denial or upstream failure)
pour api.elevenlabs.io · api.cartesia.ai · api.openai.com · api.deepgram.com · api.assemblyai.com
· api.sync.so · api.hedra.com · fal.run · api.replicate.com · cloudflarestorage.com ·
francecentral.tts.speech.microsoft.com
```

Les hôtes Google répondent, eux, applicativement :

```
{"error":{"code":403,"message":"Method doesn't allow unregistered callers ... Please use API
Key","status":"PERMISSION_DENIED"}}
```

La distinction est décisive. Le DNS résout pour les 14 hôtes. Les fournisseurs bloqués sont coupés *avant la poignée de main TLS* ; Google répond une erreur d'API. Ce n'est donc pas un problème de credentials — c'est une politique réseau, et elle laisse passer exactement un fournisseur.

3. Sélection des providers

La contrainte, et non la qualité, décide de la sélection. Google Cloud couvre **TTS + ASR + vidéo + personnage + stockage avec un seul credential**.

CATÉGORIE	PRIMARY	SECONDARY	RAISON
TTS	Google Cloud TTS <code>fr-FR</code>	ElevenLabs · Azure	seul TTS joignable
ASR	Google Cloud STT <code>fr-FR</code>	Deepgram · AssemblyAI	joignable ; horodatages mot à mot
Vidéo (contrôle E5)	Veo 3.1 Lite	fal.ai · Replicate	E5 est un contrôle équitable, pas une quête du meilleur générateur
Personnage / plans	Veo 3.1 Lite	—	produit les 10 plans sans acteur humain , donc sans consentement de tiers
Lip-sync	sync.so (<i>candidat</i>)	Hedra · LatentSync	aucun joignable — et Google n'en propose aucun
Stockage / rendu	disque local · ffmpeg 7.0.2	GCS	déjà validés sur 20 publicités

RÉSERVE ASSUMÉE SUR LES PRIX

Tous les tarifs de `provider_matrix.csv` proviennent de **comparatifs secondaires** consultés en septembre 2026 — jamais d'une page officielle ni d'une facture. Ils portent la mention (*source secondaire*). Les prix Google sont marqués `UNKNOWN_verify_official`. **Aucun champ n'a été inventé : inconnu = UNKNOWN.**

4. La dépendance la plus dangereuse

Le lip-sync

POURQUOI

OPTIONS

LEVÉE

NOTE

Elle est **unique** (aucune redondance joignable), **bloquante pour H1** (sans elle, P0 ne peut pas conclure) et **dominante économiquement** — ~87 % du coût variable mesuré en M03.

API tierce : bloquée par la politique réseau. **Auto-hébergé** (LatentSync, Wav2Lip) : aucun GPU dans cet environnement (`/dev/nvidia*` absent) et hôtes de poids injoignables. **Équivalent Google** : n'existe pas.

Autoriser l'hôte dans la politique du proxy, **ou** exécuter le harnais sur une machine à réseau ouvert.

C'est le seul bloqueur du projet qui ne se résout pas avec de l'argent.

CRITIQUE

5. Budget et plan d'exécution

POSTE	LOW	BASE	HIGH	PAYANT ?
E1 · banque de plans (25 générations)	25 \$	50 \$	100 \$	oui
E2 · TTS (~9 100 caractères)	< 1 \$	< 1 \$	2 \$	palier gratuit probable
E3 · lip-sync (50 clips)	3 \$	8 \$	25 \$	oui

POSTE	LOW	BASE	HIGH	PAYANT ?
E4 · ASR (~140 s)	< 1 \$	< 1 \$	1 \$	quasi gratuit
E5 · contrôle génératif	7 \$	20 \$	60 \$	oui
E6 · évaluation humaine	0 \$	0 \$	0 \$	non
E7 · régénération (100-200 runs)	40 \$	90 \$	200 \$	oui
Stockage / calcul · contingence 20 %	16 \$	35 \$	82 \$	—
TOTAL	≈ 92 \$	≈ 205 \$	≈ 470 \$	

Séquencement recommandé — ne pas tout lancer. E2 et E4 d'abord (quasi gratuits, valident la chaîne audio) → **E1 (50 \$) avec point d'arrêt** : si la cohérence du personnage échoue, l'hypothèse « banque de plans » du M02 tombe et E3, E5, E7 n'ont plus d'objet → E3 → **E6 qui tranche H1** → E5 et E7 **seulement si H1 passe**.

COÛT JUSQU'À LA DÉCISION H1 : ENVIRON 60 \$

Mesurer le facteur de régénération d'un pipeline dont la qualité est rejetée serait de l'argent perdu. Le garde-fou le plus important est `DRY_RUN=true` par défaut : aucune dépense accidentelle possible au premier lancement.

6. Seuils H1, fixés maintenant

Posés **avant** l'expérience, précisément pour qu'ils ne puissent pas être choisis après coup afin d'obtenir un PASS.

VERDICT	CONDITION
H1 = PASS	Publishability Rate ≥ 60 % ET Blind Mean Score ≥ 3,5/5 ET aucun critère médian < 3,0
H1 = FAIL	Publishability Rate < 35 % ou Product Fidelity médiane < 3,0
H1 = INCONCLUSIVE	entre les deux, ou accord inter-juges insuffisant (écart-type > 1,2)

Biais déclaré : un panel de 3 à 5 personnes est un signal fort, pas une mesure statistique. Il tranche H1 parce qu'aucune alternative moins coûteuse n'existe.

7. Les trois bloqueurs et leur action minimale

#	BLOQUEUR	ACTION MINIMALE	EFFET
1	Aucune clé Google Cloud	créer un projet, activer Text-to-Speech, Speech-to-Text et l'API Gemini, poser <code>GOOGLE_API_KEY</code>	débloque E1, E2, E4, E5 — 4 expériences sur 7
2	Hôtes lip-sync refusés au <code>CONNECT</code> du proxy	autoriser l'hôte dans la politique réseau, ou exécuter le harnais sur une machine à réseau ouvert	débloque E3, donc H1, donc E7
3	Aucun évaluateur	recruter 3 à 5 francophones du marché visé	débloque E6, qui tranche H1

8. Ce que M05 a produit

LIVRABLE	CONTENU
Matrice + sélection providers	18 candidats, sources citées, champs <code>UNKNOWN</code> assumés ; PRIMARY/SECONDARY justifiés par la contrainte réelle

LIVRABLE	CONTENU
Environnement + connectivité	mesurés : 4 vCPU, 16 Go, aucun GPU, 14 endpoints testés, preuve du refus proxy
Smoke tests	harnais exécutable ; déclare SKIPPED et jamais PASS sans credential. Rendu local : PASS
Contrat de pipeline	porte l'invariant M04 : la durée vient du synthétiseur , jamais du nombre de mots
Schémas, taxonomie, observabilité	13 types d'artefacts · 15 classes de panne · logs JSONL sans secrets
Manifestes + consentement	personnage, plans, produit, registre de droits — aucun visage réel, donc aucun consentement de tiers requis
Sécurité	12 points ; 2 marqués UNKNOWN (DPA fournisseur non lus)
Protocole d'évaluation	seuils H1 fixés avant l'expérience
Budget + plan	LOW/BASE/HIGH, séquencé avec points d'arrêt, garde-fous actifs

9. Formulaire de revue

RÉF.	VALIDÉ	À CORRIGER	COMMENTAIRE
Conduite de M05			
N1 Verdict BLOCKED malgré 19/19 livrables	☐	☐	
N2 Google Cloud en PRIMARY sur 4 catégories (mono-fournisseur assumé pour P0)	☐	☐	
N3 Personnage généré plutôt qu'acteur réel (évite le consentement de tiers)	☐	☐	
N4 Seuils H1 fixés avant l'expérience	☐	☐	
N5 Séquencement avec arrêt après E1 si l'identité dérive	☐	☐	
Décisions à prendre			
A1 Créer le projet Google Cloud et fournir la clé		réponse :	
A2 Lever le blocage réseau lip-sync (allowlist ou autre machine)		réponse :	
A3 Recruter 3 à 5 évaluateurs francophones		réponse :	
A4 Approuver l'enveloppe ≈ 205 \$ (60 \$ jusqu'à H1)		réponse :	
A5 Fournir un produit client réel, ou garder le produit de test		réponse :	

Verdict global

☐ Paquet M05 validé — approvisionner puis exécuter E1 → E7 ☐ Validé sous réserve ☐ À reprendre

Nom du relecteur	Date	Signature
Afrinext · Rapport de jalon M05 · Provider Procurement & Experiment Setup		Document interne · pour revue